

Studi Literatur: Deteksi Depresi Berbasis Audio

Proyek: Mentalhealth — Klasifikasi Kesehatan Mental Berbasis Audio

Peran: ML & Data Engineer (Athila Ramdani Saputra)

Fase: W1 — Riset & Literatur

Tanggal: Mei 2026

1. Pendahuluan

Kesehatan mental merupakan salah satu krisis kesehatan global yang paling mendesak, namun sangat kurang terdiagnosis akibat minimnya akses ke tenaga profesional psikologi [Haque et al., 2021]. Pendekatan berbasis kecerdasan buatan (AI), khususnya analisis sinyal suara, menawarkan solusi skrining yang otomatis, non-invasif, dan skalabel [Yadav et al., 2023]. Suara manusia mengandung sejumlah fitur akustik yang secara klinis terbukti berkorelasi dengan kondisi psikologis, seperti depresi, kecemasan, dan stres [Jaiswal et al., 2019].

Studi literatur ini merangkum penelitian terkini terkait deteksi depresi berbasis audio menggunakan pendekatan Machine Learning (ML) dan Deep Learning (DL), khususnya yang relevan dengan tugas seorang **ML & Data Engineer**: preprocessing audio, ekstraksi fitur akustik, training model ML klasik, dan penerapan Explainable AI (XAI).

2. Dataset yang Relevan

2.1 DAIC-WOZ (Distress Analysis Interview Corpus)

Dataset DAIC-WOZ terdiri dari 189 sesi wawancara klinis antara partisipan manusia dan agen AI virtual bernama "Ellie", yang dirancang untuk mengidentifikasi tanda-tanda gangguan psikologis seperti depresi dan PTSD [Gratch et al., 2014]. Setiap sesi dilengkapi dengan file audio .wav, transkrip percakapan, fitur akustik pra-ekstrak (COVAREP .csv), serta fitur visual dari OpenFace [Gratch et al., 2014]. Label depresi pada dataset ini diukur menggunakan skor **PHQ-8** (Patient Health Questionnaire-8), dengan skor ≥ 10 dikategorikan sebagai depresi [Gratch et al., 2014].

[!CAUTION]

Terdapat jebakan metodologis kritis (common pitfalls) yang sering terjadi saat menggunakan DAIC-WOZ. Penelitian Danylenko & Unold (2025) mengidentifikasi bahwa model yang dilatih tanpa memisahkan data berdasarkan **Participant ID** (bukan per segment) rentan terhadap subject leakage, di mana fragmen suara dari orang yang sama muncul di data train dan test sekaligus. Kondisi ini menghasilkan akurasi yang tampak tinggi namun tidak mencerminkan kemampuan generalisasi yang sebenarnya [Danylenko & Unold, 2025].

Selain itu, Danylenko & Unold (2025) memperingatkan agar suara pewawancara (Ellie) tidak ikut dimasukkan ke dalam fitur, karena model akan cenderung "mengenal" pola pertanyaan pewawancara alih-alih mengenali sinyal depresi pada partisipan [Danylenko & Unold, 2025]. Penelitian ini juga merekomendasikan penggunaan metrik R^2 (Coefficient of Determination) di samping MAE untuk evaluasi yang lebih bermakna, karena banyak model ML di DAIC-WOZ performanya setara atau lebih buruk dari prediktor *mean* naif [Danylenko & Unold, 2025].

2.2 MODMA (Multi-modal Open Dataset for Mental-disorder Analysis)

Dataset MODMA dikembangkan oleh Lanzhou University dan mencakup data dari 52 partisipan (29 Healthy Control / HC, dan 23 Major Depressive Disorder / MDD) yang merekam suara dalam kondisi laboratorium terkontrol [Cai et al., 2022]. Berbeda dengan DAIC-WOZ yang bersifat percakapan bebas, MODMA menggunakan protokol *task-oriented* yang terstruktur — setiap partisipan menyelesaikan 29 tugas suara yang identik, mencakup: 18 sesi wawancara (file 01-18), 1 sesi membaca paragraf (file 19), 6 sesi membaca kata (file 20-25), dan 4 sesi deskripsi gambar (file 26-29) [Cai et al., 2022].

Kekuatan utama MODMA adalah kekayaan metadata klinisnya. Selain label diagnosis biner (MDD/HC), dataset ini menyediakan skor kontinu dari berbagai kuesioner psikologi standar, meliputi PHQ-9, GAD-7, LES (*Life Events Scale*), CTQ-SF (*Childhood Trauma Questionnaire*), dan PSQI (*Pittsburgh Sleep Quality Index*) [Cai et al., 2022]. Hal ini membuka peluang untuk eksperimen pemodelan regresi guna memprediksi tingkat keparahan kondisi secara numerik, bukan hanya mengklasifikasikan secara biner [Cai et al., 2022].

Penelitian Gaofeng et al. (2023) yang secara spesifik menggunakan dataset MODMA menemukan bahwa tugas **deskripsi gambar (file 26-29)** menghasilkan sinyal depresi yang paling kuat karena memicu ekspresi emosional yang spontan dan tidak terstruktur, berbeda dengan tugas membaca yang cenderung monoton [Gaofeng et al., 2023].


3. Fitur Akustik untuk Deteksi Depresi

3.1 Mel-Frequency Cepstral Coefficients (MFCC)

MFCC merupakan representasi sinyal audio yang paling dominan digunakan dalam berbagai penelitian deteksi depresi berbasis suara [Agbo et al., 2024]. MFCC mengonversi sinyal audio ke dalam domain frekuensi berdasarkan persepsi pendengaran manusia menggunakan skala Mel, sehingga lebih sesuai untuk menganalisis karakteristik suara manusia dibandingkan transformasi frekuensi linear biasa [Agbo et al., 2024]. Penelitian Agbo et al. (2024) melakukan perbandingan komprehensif antara MFCC dan fitur berbasis Wavelet, dan menyimpulkan bahwa MFCC mengungguli Wavelet dalam sebagian besar skenario klasifikasi emosi pada suara [Agbo et al., 2024].

Pada proyek ini, MFCC diekstrak dengan 13 koefisien (mfcc_1 hingga mfcc_13), dan setiap koefisien direpresentasikan oleh dua statistik agregat: mean dan standar deviasi [Li et al., 2025]. Pendekatan

agregasi statistik ini mengubah representasi berbasis frame (per 10ms) menjadi vektor fitur tunggal per partisipan, yang cocok untuk model ML klasik seperti SVM dan Random Forest [Li et al., 2025].



Gambar 1. Fig. 1 dari Wu et al. (2024): (A) Linear Predictive Coding (LPC) dan (B) MFCC — menampilkan sinyal asli suara (biru) beserta peta warna fitur akustik yang diekstrak. Sumber: "Audio Frequency-Time Dual Domain Evaluation on Depression Diagnosis" [Wu et al., 2024].

3.2 Pitch (F0 — Frekuensi Dasar)

Pitch atau frekuensi dasar (F0) merupakan karakteristik prosodik suara yang paling sering dikaitkan dengan kondisi depresi secara klinis [Yadav et al., 2023]. Penderita depresi secara konsisten menunjukkan **rentang pitch yang lebih sempit** (suara yang lebih monoton) dan **pitch rata-rata yang lebih rendah** dibandingkan individu sehat [Yadav et al., 2023]. Penelitian Haque et al. (2021) juga mengonfirmasi bahwa variabilitas pitch merupakan salah satu fitur paling diskriminatif antara kelompok MDD dan HC pada dataset audio terstruktur seperti MODMA [Haque et al., 2021].

3.3 Energy (RMS Energy)

Energy atau RMS (*Root Mean Square*) merepresentasikan kekuatan amplitudo sinyal audio per satuan waktu [Yadav et al., 2023]. Literatur menunjukkan bahwa individu dengan depresi cenderung berbicara dengan energi suara yang lebih rendah, sedangkan individu dengan kecemasan (*anxiety*) justru menunjukkan peningkatan energi akibat ketegangan otot vokal [Li et al., 2025]. Oleh karena itu, fitur energy penting tidak hanya untuk membedakan depresi vs normal, tetapi juga untuk memisahkan depresi dari kecemasan sebagaimana dibutuhkan dalam proyek 3-kelas ini [Li et al., 2025].

3.4 Spectral Features (Centroid, Bandwidth, Rolloff)


Fitur spektral seperti *Spectral Centroid* (pusat gravitasi frekuensi) dan *Spectral Bandwidth* (persebaran frekuensi) menangkap karakteristik timbral suara yang tidak dapat ditangkap oleh MFCC maupun Pitch saja [Wu et al., 2024]. Penelitian Wu et al. (2024) menunjukkan bahwa *fusi fitur* berbasis spectrogram yang memadukan domain waktu dan domain frekuensi secara bersamaan menghasilkan akurasi yang lebih tinggi dibandingkan penggunaan fitur tunggal, dengan mencapai akurasi **88%** pada dataset MODMA dan **90%** pada EATD-Corpus [Wu et al., 2024].

3.5 Voice Activity Detection (VAD)

Sebelum ekstraksi fitur, langkah *Voice Activity Detection* (VAD) sangat direkomendasikan untuk membuang bagian hening (*silence*) yang tidak mengandung informasi akustik relevan [Gaofeng et al., 2023]. Tanpa VAD, statistik rata-rata fitur seperti Pitch dan Energy akan terdistorsi secara signifikan oleh bagian tanpa suara, terutama pada dataset seperti MODMA di mana durasi jeda antar tugas bervariasi [Gaofeng et al., 2023].

4. Alur Sistem Deteksi Depresi Berbasis Audio

Berdasarkan sintesis dari seluruh literatur yang ditinjau, alur sistem deteksi depresi berbasis audio secara umum terdiri dari lima tahap [Yadav et al., 2023]:



Gambar 2. Figure 1 dari Gaofeng et al. (2023): Arsitektur framework Wav2Vec 2.0 XLSR-53 — menampilkan alur dari raw waveform → shared CNN encoder → Transformer blocks → task-specific heads. Sumber: "Application of Pre-trained Model-based Speech Analysis in Depression Detection" [Gaofeng et al., 2023].

1. **Input Audio:** Merekam atau menerima file .wav dari partisipan [Yadav et al., 2023].

2. **Preprocessing:** Melakukan resampling ke 16kHz, VAD untuk membuang hening, dan normalisasi amplitudo [Gaofeng et al., 2023].
 3. **Ekstraksi Fitur:** Menghitung MFCC, Pitch F0, Energy RMS, dan Spectral Features, kemudian mengagregasinya (mean, std) menjadi satu vektor fitur per partisipan [Agbo et al., 2024].
 4. **Klasifikasi:** Melatih dan mengevaluasi model ML (SVM, Random Forest, XGBoost) atau DL (CNN, LSTM, Wav2Vec) [Danylenko & Unold, 2025].
 5. **Penjelasan (XAI):** Menggunakan SHAP atau LIME untuk menjelaskan kontribusi setiap fitur audio terhadap prediksi model [Li et al., 2025].
-

5. Perbandingan Model Machine Learning

5.1 Support Vector Machine (SVM)

SVM merupakan model ML klasik yang paling sering digunakan sebagai *baseline* dalam penelitian deteksi depresi berbasis audio [Yadav et al., 2023]. Keunggulan SVM adalah kemampuannya bekerja dengan baik pada dataset dimensi tinggi dan ukuran sampel yang relatif kecil, yang merupakan karakteristik umum dataset audio klinis seperti DAIC-WOZ dan MODMA [Yadav et al., 2023]. Penelitian Yadav et al. (2023) melaporkan bahwa SVM dengan kernel RBF menggunakan fitur gabungan MFCC dan prosodic mencapai akurasi sekitar **74%** pada DAIC-WOZ, yang menjadi target baseline untuk proyek ini [Yadav et al., 2023].


5.2 Random Forest & Ensemble Methods

Random Forest menawarkan keunggulan berupa *built-in feature importance*, yang secara langsung menunjukkan fitur audio mana yang paling berpengaruh terhadap prediksi — sangat berguna untuk kebutuhan XAI proyek ini [Haque et al., 2021]. Penelitian Haque et al. (2021) menggunakan Random Forest dengan fitur akustik multi-modal (behavioral dan voice) dan berhasil mencapai akurasi **72-80%** tergantung kombinasi fitur yang digunakan [Haque et al., 2021]. Selain itu, penelitian Sharma et al. (2025) memperkenalkan *NeuroVibeNet*, sebuah metode ensemble berbasis swarm-optimized neural network yang diklaim mencapai akurasi **99.06%** — meskipun hasil ini perlu diverifikasi ulang karena kemungkinan besar terjadi *overfitting* atau *data leakage* [Sharma et al., 2025].

5.3 XGBoost

XGBoost (*Extreme Gradient Boosting*) merupakan model ensemble berbasis *gradient boosting* yang secara empiris sering mengungguli SVM dan Random Forest dalam kompetisi data science [Danylenko & Unold, 2025]. Keunggulan tambahan XGBoost dalam konteks proyek ini adalah kompatibilitas natifnya dengan **SHAP** (*SHapley Additive exPlanations*) — library SHAP memiliki *TreeExplainer* yang dioptimalkan khusus untuk model berbasis pohon seperti XGBoost, sehingga penjelasan XAI dapat dihasilkan jauh lebih cepat [Danylenko & Unold, 2025].

5.4 Perbandingan Akurasi dari Literatur



Gambar 3. Fig. 3 dari Li et al. (2025): Taksonomi komprehensif domain deteksi depresi berbasis audio — merangkum modalitas data, representasi fitur (LLDs, MFCC, prosodi), arsitektur model (ML Tradisional vs Deep Learning), hingga strategi evaluasi. Sumber: "Automated Depression Detection From Text and Audio: A Systematic Review" [Li et al., 2025].

Model	Fitur	Dataset	Akurasi	Sumber
SVM (RBF)	MFCC + Prosodic	DAIC-WOZ	~74%	Yadav et al., 2023
Random Forest	Behavioral + Voice	Custom	~72-80%	Haque et al., 2021
NeuroVibeNet (Ensemble)	MFCC	Custom	99.06%	Sharma et al., 2025
Enhanced Feature Fusion	Multi-domain Spectrogram	MODMA	88%	Wu et al., 2024
CNN (1D, MFCC)	MFCC	MODMA	~61%	Gaofeng et al., 2023
LSTM (MFCC)	MFCC	MODMA	~56%	Gaofeng et al., 2023

Wav2Vec 2.0 XLSR	Pre-trained	MODMA	89.5%	Gaofeng et al., 2023
---------------------	-------------	-------	-------	-------------------------

**Perlu verifikasi lebih lanjut — kemungkinan overfitting.*

[!NOTE]

Dari tabel di atas, dapat disimpulkan bahwa model ML tradisional (SVM, RF) dengan fitur manual (MFCC) umumnya berada di rentang 72-80% akurasi, sementara model DL pre-trained (Wav2Vec 2.0) dapat melampaui 89%. Target realistis untuk model ML yang akan dikembangkan dalam proyek ini adalah $\geq 75\%$ **F1-Score** [Danylenko & Unold, 2025].

6. Explainable AI (XAI) untuk Model ML

6.1 SHAP (SHapley Additive exPlanations)

SHAP adalah metode XAI yang paling populer dan matang untuk model Machine Learning, terinspirasi dari teori permainan (*game theory*) [Li et al., 2025]. SHAP mengkuantifikasi kontribusi setiap fitur terhadap prediksi individual maupun prediksi global model, menjadikannya sangat berguna untuk membangun kepercayaan klinis terhadap prediksi AI [Li et al., 2025]. Penelitian Li et al. (2025) menggunakan SHAP untuk menginterpretasi model RF pada data depresi dan menemukan bahwa fitur-fitur prosodic (terutama statistik Pitch) memiliki nilai SHAP tertinggi, mengkonfirmasi relevansi klinis fitur tersebut [Li et al., 2025].

6.2 LIME (Local Interpretable Model-agnostic Explanations)

LIME bekerja dengan membuat perturbasi kecil pada input data dan mengamati perubahan output model untuk mendapatkan penjelasan lokal per-instance [Li et al., 2025]. LIME bersifat *model-agnostic*, artinya dapat diaplikasikan pada model apa pun termasuk SVM yang tidak secara native mendukung interpretasi fitur [Li et al., 2025]. Namun, LIME lebih tidak stabil (hasil bisa berbeda tiap run) dibandingkan SHAP, sehingga disarankan untuk digunakan bersama-sama sebagai validasi silang [Danylenko & Unold, 2025].

7. Kesimpulan & Implikasi untuk Proyek

Berdasarkan sintesis dari 8 paper yang ditinjau, berikut adalah poin-poin krusial yang secara langsung mempengaruhi pengembangan pipeline ML pada proyek Menthealth:

- Fitur Prioritas:** MFCC (13 koefisien, mean + std), Pitch F0, RMS Energy, dan Spectral Centroid merupakan fitur paling esensial dan terbukti efektif [Agbo et al., 2024; Yadav et al., 2023].

- 2. **Preprocessing Wajib:** Resampling ke 16kHz dan VAD untuk membuang keheningan harus dilakukan sebelum ekstraksi fitur [Gaofeng et al., 2023].
- 3. **Pencegahan Leakage:** Pembagian data train/test wajib dilakukan berdasarkan **Participant ID**, bukan berdasarkan segment audio [Danylenko & Unold, 2025].
- 4. **Task-Specific Feature:** Pada MODMA, fokuskan EDA dan ekstraksi fitur pada file tugas deskripsi gambar (26-29) yang memiliki sinyal depresi paling kuat [Gaofeng et al., 2023].
- 5. **Target Akurasi:** Target baseline realistis untuk model SVM/RF di atas dataset ini adalah **72-80%** — angka di atas ini patut dicurigai adanya *leakage* [Danylenko & Unold, 2025].
- 6. **XAI:** Gunakan SHAP sebagai metode utama (native support untuk XGBoost/RF) dan LIME sebagai validasi untuk SVM [Li et al., 2025].

8. Daftar Referensi

ID	Penulis	Tahun	Judul	Jurnal/Konferensi
[Agbo et al., 2024]	Agbo, I., et al.	2024	Comparative Analysis of MFCC and Wavelet-Based Audio Signal Processing for Emotion Detection and Mental Health Assessment in Spoken Speech	IEEE/Academic Journal
[Cai et al., 2022]	Cai, H. et al.	2022	MODMA Dataset: a Multi-modal Open Dataset for Mental-disorder Analysis	Nature Scientific Data
[Li et al., 2025]	Li, Y., et al.	2025	Automated Depression Detection From Text and Audio: A Systematic Review	Journal of Medical Internet Research (JMIR)

[Yadav et al., 2023]	Yadav, P., et al.	2023	Depression Detection through Audio Analysis using Machine Learning Models Ensuring Sustainable Development of Mankind	Sustainability (MDPI)
[Gaofeng et al., 2023]	Gaofeng, M. et al.	2023	Application of Pre-trained Model-based Speech Analysis in Depression Detection: A Multi-task Feature Study on the MODMA Dataset	Frontiers in Psychiatry
[Gratch et al., 2014]	Gratch, J. et al.	2014	The Distress Analysis Interview Corpus of human and computer interviews	LREC
[Haque et al., 2021]	Haque, M. A. et al.	2021	Early Detection of Mental Health Disorders Using Machine Learning Models using Behavioral and Voice Data Analysis	Procedia Computer Science

[Sharma et al., 2025]	Sharma, A. et al.	2025	Efficacy of Swarm-Based Neural Networks in Automated Depression Detection	Neural Computing & Applications
[Wu et al., 2024]	Wu, Y. et al.	2024	Enhanced Depression Detection through Optimally Weighted Spectrogram Feature Fusion	Biomedical Signal Processing and Control
[Danylenko & Unold, 2025]	Danylenko, I., & Unold, O.	2025	Common Pitfalls and Recommendations for Use of Machine Learning in Depression Severity Estimation: DAIC-WOZ Study	JMIR Mental Health

Dokumen ini disiapkan untuk memenuhi tugas Fase W1 — Studi Literatur Audio Depression Detection pada proyek Menthealth.
Penulis: Athila Ramdani Saputra (ML & Data Engineer)